

ITM.690 인공지능 경영과 법 · 2026 가을 · 1강

인공지능의 기본 개념

인공지능은 결국 “함수”다. 규칙 기반 접근에서 머신러닝, 인공신경망, 딥 러닝으로 이어지는 흐름을 따라가며, 인공지능이 무엇을 할 수 있고 무엇을 할 수 없는지 이해한다.

2026. 9. 3.

김병필 · KAIST 기술경영전문대학원

1

인공지능

인공지능 = 함수

2

머신러닝

데이터로부터 함수 찾기

3

인공신경망

뉴런을 쌓아 만든 함수

4

딥 러닝

깊게 쌓으면 왜 강해지나

5

미래 인공지능

전문가들은 언제라고 보나

들어가며

인공지능 기술의 발전




게임 AI (1998)



차량 내비게이션 (2013)



스타크래프트 II 인공지능 (AlphaStar)



자율주행차의 인식 화면

10년 동안 어떠한 기술 발전이 있었던 것일까?

들어가며

용어부터 정리하기

- 인공지능 (Artificial Intelligence)
- 머신러닝 (Machine Learning)
- 인공신경망 (Neural Networks)
- 딥 러닝 (Deep Learning)

네 용어는 서로 별개의 것이 아니라 포함 관계에 있다. 이 강의는 바깥쪽부터 안쪽으로 한 겹씩 들어간다.

인공지능

가장 바깥 층. “인공지능”이라는 말이 실제로 무엇을 가리키는지부터 정리한다.



인공지능 = 함수


$$\underbrace{f}_{\text{인공지능}} \left(\underbrace{\hspace{2cm}}_{\text{입력 변수}} \right) = \underbrace{\hspace{2cm}}_{\text{출력 변수}}$$

인공지능은 입력 변수를 받아 출력 변수를 내놓는 함수로 볼 수 있다.


인공지능 = 함수

$$\begin{array}{c} \text{인공지능} \\ \hline f \end{array} \left(\begin{array}{c} \text{입력 변수} \\ \text{(주변 맵 정보)} \\ \hline \end{array} \right) = \begin{array}{c} \begin{array}{c} \text{출력 변수} \\ \text{(어느 유닛을 공격하지?)} \\ \hline \end{array} \end{array}$$


인공지능 = 함수

$$\underset{\text{인공지능}}{\underline{f}} \left(\underset{\substack{\text{입력 변수} \\ \text{(현재 바둑판 기보)}}}{\text{인공지능}} \right) = \underset{\substack{\text{출력 변수} \\ \text{(다음에 놓을 수)}}}{\text{인공지능}}$$


"인공지능"의 구현 = 함수 찾기



인공지능 교과서

차례

• 역자의 글	xiv
• 서문	xv
• 저자 소개	xxi
• 베타리더 후기	xxii

1권

CHAPTER 1 소개 • 1

1.1 인공지능이란 무엇인가?	2
1.2 인공지능의 기반 학문	6
1.3 인공지능의 역사	20
1.4 인공지능의 현재 수준	35
1.5 요약	37
• 연습문제	39

CHAPTER 2 지능적 에이전트 • 43

2.1 에이전트와 환경	44
2.2 좋은 행동: 합리성 개념	46
2.3 환경의 특성	51
2.4 에이전트의 구조	58
2.5 요약	73
• 연습문제	76

CHAPTER 3 검색을 통한 문제 해결 • 79

3.1 문제 해결 에이전트	80
3.2 문제의 예	86
3.3 해답의 검색	92
3.4 정보 없는 검색 전략	99
3.5 정보 있는(탐색법) 검색 전략들	112
3.6 발견법적 함수	124
3.7 요약	131
• 연습문제	138

CHAPTER 4 고급 검색 기법 • 147

4.1 국소 검색 알고리즘과 최적화 문제	148
4.2 연속 공간의 국소 검색	158
4.3 비결정론적 동작들을 수반한 검색	162
4.4 부분 관찰 가능 환경의 검색	168
4.5 온라인 검색 에이전트와 미지 환경	178
4.6 요약	186
• 연습문제	191

CHAPTER 5 대항 검색 • 195

5.1 게임	195
5.2 게임의 최적 결정	198
5.3 알파베타 가지치기	202
5.4 불완전한 실시간 결정	207
5.5 확률론적 게임	214
5.6 부분 관찰 가능 게임	218
5.7 최고 수준의 게임 플레이 프로그램들	224
5.8 대안 접근법들	227
5.9 요약	229
• 연습문제	237


CHAPTER 6 제약 만족 문제 • 245

6.1 제약 만족 문제의 정의	246
6.2 제약 전파: CSP의 추리	252
6.3 CSP를 위한 역추적 검색	260
6.4 CSP를 위한 국소 검색	267
6.5 문제의 구조	269
6.6 요약	275
• 연습문제	280

CHAPTER 7 논리적 에이전트 • 285

7.1 지식 기반 에이전트	286
7.2 원무스 세계	288
7.3 논리	292
7.4 명제 논리: 아주 간단한 논리	296
7.5 명제 정리 증명	303
7.6 효과적인 명제 모형 증명	316
7.7 명제 논리에 기초한 에이전트	322

"인공지능"의 구현 방식




AlphaGo




→ 알파고, 자율주행차 등 최근의 성과는 대부분 머신러닝 방식

규칙기반 접근 (Rule-based Approach)



- 공격 규칙 (rule)
 - 상대방 공격 유닛 > 상대방 비공격 유닛
 - 공격력 강한 유닛 > 공격력 약한 유닛
 - 가까운 유닛 > 먼 유닛
 - ...

전문가 시스템



- MYCIN (1975) – 항생제 처방 추천
 - 100여 가지 박테리아 감염 정보 저장
 - 증상, 상태, 치료 이력, 검사 결과 등 입력
 - 감염 여부·박테리아 유형 판단, 치료법 추천

https://en.wikipedia.org/wiki/Expert_system



Symbolics 3640 — 1980년대 전문가 시스템 개발에 쓰인 리스프 머신

법률 전문가 시스템 (expert system)

```
Which X : X is father of Peter ? William
Which X : William was born on date X ? (1 March 1952)
Is it true that William died before (3 May 1983) ? no
Is it true that William was born in the U.K. ? yes
Is it true that William was found as a newborn infant
abandoned in the U.K. ? no
Is it true that William was adopted ? no
Is it true that William was a citizen of the U.K. and
Colonies on date (31 Dec 1982) ? yes

:


Is it true that Peter has ever renounced British citizenship ? no
Is it true that Peter has ever been deprived of British
citizenship by section 40 ? no

Yes, I can confirm that
Peter is a British citizen on date (16 Jan 1984) by sect. 1.1 how

Sergot et al. (1986), "The British Nationality Act as a Logic Program"
```

- 한계
 - 저장된 규칙의 수가 200 내지 300건에 이르면 실행 성능이 저하
 - 관리자가 규칙을 일일이 유지 관리하는 것이 사실상 불가능

머신러닝 방식




프로게이머들의 플레이 방식을 배워보면 어떨까?

데이터를 학습하는 인공지능 = 머신러닝 (Machine Learning)


머신러닝의 활용 - 알파고

$$\underbrace{f}_{\text{인공지능}} \left(\underbrace{\text{입력 변수}}_{\text{(현재 바둑판 기보)}} \right) = \underbrace{\text{출력 변수}}_{\text{(다음에 놓을 수)}}$$



→ 수많은 프로 기사 기보(입력-출력 쌍)를 학습하여
"다음 수"를 내놓는 함수를 찾아냄

인공지능의 구분



인공지능

AI Apocalypse



닉 보스트롬, 『슈퍼인텔리전스 — 경로, 위험, 전략』

인공지능

이번 강의의 주제 = ANI



AGI — 이번 강의의 주제가 아님



ANI — 오이 등급 분류 인공지능

ANI의 활용 사례

$$f\left(\text{📶}\right) = \text{"Siri야"}$$

$$f\left(\text{你好}\right) = \text{"안녕하세요"}$$

$$f\left(\text{🏠}\right) = \text{폐렴이 있는지?}$$

음성 인식, 기계 번역, 의료 영상 판독 — 모두 "입력을 출력으로 대응시키는 함수"다.

머신러닝

데이터로부터 함수를 찾아내는 방법. 가장 단순한 예인 선형 회귀로 원리를 이해한다.

인공지능

머신러닝

인공신경망


딥 러닝



머신러닝 = 데이터로부터 함수 찾기

- 아주 간단한 사례 - 데이터
 - 입력 값: 아파트 면적
 - 출력 값: 아파트 가격
- 문제: 입력 값과 출력 값의 관계는?

$$f(\text{아파트 면적}) = \text{아파트 가격}$$




→ 선형회귀

단순 선형 회귀

- 가설(Hypothesis): 주어진 데이터를 표현하는 함수
- 단순 선형 회귀의 가설

$$y = f(x) = ax + b$$


- 컴퓨터에게 시킬 일
 - 주어진 데이터를 가장 잘 표시하는 a 값과 b 값을 찾는 것!



a, b 가 달라지면 직선도 달라진다

예제 데이터

데이터 x	데이터 y
0	0
1	2
2	4
3	6



문제: x 와 y 사이의 관계는?

슬쩍 봐도 $y = 2x$ 네! 너무 쉬운데?
하지만 컴퓨터는 직관적으로 알 수가 없음

"겐또"라는 말을 아시나요?



일본어 '見当(けんとう)'에서 온 말로, '어림짐작'·'예측'을 뜻한다. 컴퓨터도 처음에는 찍어 볼 수밖에 없다.

가설의 비용

- 오차 = 컴퓨터가 세운 가설과 실제 데이터 사이의 차이를 제곱 [가설이 $y = 0.5x$ 인 경우의 예시]

데이터 x	데이터 y	가설 $\hat{y} = 0.5x$	오차 $y - \hat{y}$	오차의 제곱 $(y - \hat{y})^2$
0	0	0	0	0
1	2	0.5	$2 - 0.5 = 1.5$	2.25
2	4	1.0	$4 - 1 = 3.0$	9.0
3	6	1.5	$6 - 1.5 = 4.5$	20.25

- 오차의 평균 (= 가설의 비용)

$$Cost = \frac{\{(0 - 0)^2 + (2 - 0.5)^2 + (4 - 1.0)^2 + (6 - 1.5)^2\}}{4} = 7.875$$

머신러닝 학습 방법

- 단순한 학습 방법 - 가설을 조금 바꿔보기 [가설이 $y = 0.4x$ 인 경우의 예시]

데이터 x	데이터 y	가설 $\hat{y} = 0.4x$	오차 $y - \hat{y}$	오차의 제곱 $(y - \hat{y})^2$
0	0	0	0	0
1	2	0.4	$2 - 0.4 = 1.6$	2.56
2	4	0.8	$4 - 0.8 = 3.2$	10.24
3	6	1.2	$6 - 1.2 = 4.8$	23.04

- 오차의 평균 (= 가설의 비용)

$$Cost = \frac{\{(0 - 0)^2 + (2 - 0.4)^2 + (4 - 0.8)^2 + (6 - 1.2)^2\}}{4} = 8.96$$

머신러닝 학습 방법

- 단순한 학습 방법 - 가설을 조금 바꿔보기 [가설이 $y = 0.6x$ 인 경우의 예시]

데이터 x	데이터 y	가설 $\hat{y} = 0.6x$	오차 $y - \hat{y}$	오차의 제곱 $(y - \hat{y})^2$
0	0	0	0	0
1	2	0.6	$2 - 0.6 = 1.4$	1.96
2	4	1.2	$4 - 1.2 = 2.8$	7.84
3	6	1.8	$6 - 1.8 = 4.2$	17.64

- 오차의 평균 (= 가설의 비용)

$$Cost = \frac{\{(0 - 0)^2 + (2 - 0.6)^2 + (4 - 1.2)^2 + (6 - 1.8)^2\}}{4} = 6.86$$

머신러닝 = 오차의 최소화

- 예시 데이터
 - a 값이 0.5일 때 오차 평균 = 7.875
 - a 값이 0.4일 때 오차 평균 = 8.96
 - a 값이 0.6일 때 오차 평균 = 6.86
 - 컴퓨터는 a 값을 늘려야 할까? 줄여야 할까?
 - **a 값이 증가하면 오차가 줄어듦**
 - **a 값을 더 증가시키면서 위 과정을 계속 반복함**
- 비용 함수 (cost function)
 - 주어진 데이터에 가설을 적용했을 때 그 오차를 함수로 표현한 것
 - 손실 함수(loss function) 또는 목적 함수(objective function)라고도 함
- 머신러닝의 목적
 - **비용함수를 최소화하는 a, b 값을 찾는 것!**

다중 선형 회귀

- 하나의 변수(x)만으로 결과(y)를 설명할 수 있는 경우는 거의 없음
 - 다중 선형 회귀: 다수의 x 변수를 이용해서 y 값을 예측하기
- 예시 - 아파트 가격 (y)
 - x_1 = 아파트 평수
 - x_2 = 방 개수
 - x_3 = 층 수

x_1 (평)	x_2 (개)	x_3 (층)	y (억)
18	2	5	2.1
32	3	10	3.4
...	...	...	...
48	4	3	5.8

다중 선형 회귀


- 가설을 세워 보자!

$$y = w_1x_1 + w_2x_2 + w_3x_3 + b$$

- 비용 함수
 - 가설의 예측 값과 학습 데이터 간의 오차의 제곱값을 평균
- 가중치 찾기
 - w_1, w_2, w_3, b 값을 조금씩 바꿔 가면서 비용 함수를 최소화하는 w_1, w_2, w_3, b 값 찾기

응용 사례 – 와인 가격 예측하기

- 프린스턴 대학 경제학자는 와인 가격을 예측하는 선형회귀 모델을 개발
- 입력 변수
 - 와인 빈티지 (나이)
 - 포도 성장기의 날씨
 - 수확철의 강수량
 - 겨울철의 강수량
 - ...
- 출력 변수
 - 와인의 경매 가격




Orley Ashenfelter (Princeton)

와인 평론가의 반응


"영화 평론가가 영화를 보지 않고서 배우와 감독만 보고 그 영화가 좋은지 알 수 없는 것과 마찬가지로 [데이터로 와인 가격을 예측하는 것]은 완전히 사기이다."

- 로버트 파커 (세계적으로 저명한 와인 평론가)



Robert M. Parker Jr.



와인 가격 예측하기 - 결과



Orley Ashenfelter (1986)

→ 일부 전문가들보다 오히려 경매 가격을 더 정확히 예측!

머신러닝의 기본 개념




① 가설은 주어진 데이터(x, y)를 함수로 표현한 것

② 머신러닝은 주어진 데이터에 대해 오차를 최소화하는 가설을 찾는 작업

머신러닝

이게 다 인공지능과 무슨 상관이지...



인공신경망


선형 회귀 모델을 “뉴런”으로 바꿔 부르고, 뉴런을 여러 층으로 쌓으면 인공신경망이 된다.

인공지능


머신러닝

인공신경망

딥 러닝




단순 선형회귀 모델



Input x	Output y
아파트 면적	아파트 가격

$$f \left(\text{아파트 면적} \right) = \text{아파트 가격}$$

인공 뉴런 (Artificial Neuron)




Input x	Output y
아파트 면적	아파트 가격


$$f(\text{아파트 면적}) = \text{아파트 가격}$$

선형회귀 모델과 똑같은 구조를 "뉴런"이라고 부르기로 하자.

인공 뉴런 (Artificial Neuron)




인공 뉴런 (Artificial Neuron)




$$y = f(z)$$

→ 선형(linear)이 아닌 함수도 학습 가능!



활성화 함수의 예 — 시그모이드 함수

인공 뉴런 (Artificial Neuron)




Input x_1	Input x_2	Input x_3	Output y
아파트 면적	방 개수	교통 편의성	아파트 가격

$$z = w_1x_1 + w_2x_2 + w_3x_3 + b$$


$$y = f(z)$$

$$f \left(\begin{array}{l} \text{아파트 면적} \\ \text{방 개수} \\ \text{교통 편의성} \end{array} \right) = \text{아파트 가격}$$

실제 뉴런 vs 인공 뉴런




인공 뉴런 — 입력·가중치·가중합·활성화·출력



실제 뉴런 — 수상돌기(입력)·세포체·축삭돌기(출력)·시냅스(연결 강도)



인공신경망이란?



- 인공 뉴런을 여러 단위로 쌓은 네트워크
- **인공신경망 = 복잡한 함수 표현의 일종**

$$F(x) = \sum_{i=1}^N v_i \varphi(w_i^T x + b_i)$$

초기의 (아날로그) 인공 신경망



Mark I Perceptron (1958) — 가중치를 전위차계(가변 저항)로 구현하고, 모터로 손잡이를 돌려 가중치를 조정했다.

Universal Approximation Theorem

- **Universal Approximation Theorem**


- “In the mathematical theory of artificial neural networks, the universal approximation theorem states that a feed-forward network with a single hidden layer containing a finite number of neurons can approximate continuous functions on compact subsets of $\mathbb{R}^n$, under mild assumptions on the activation function.” (Wikipedia)

TL;DR – “인공 신경망을 이용하면 어떠한 함수라도 근사(近似, approximation)해 낼 수 있다”

인공신경망의 잠재력


- **Universal Approximation Theorem**
 - 세상 만사를 수치화할 수 있고, 그렇게 수치화된 변수들의 관계를 어떤 함수로 표현할 수 있다고 가정해 봄
 - 컴퓨터로 다수의 뉴런으로 구성된 인공 신경망을 구축함
 - 만약 머신러닝의 반복을 통해 가중치를 찾아 낼 수 있다면, 인공 신경망은 세상의 어떠한 함수라도 근사해 낼 수 있음
 - **이것은 세상 만사를 컴퓨터로 근사해 낼 수 있다는 뜻!**

인공신경망과 머신러닝




Quiz 위 인공신경망은 가중치($w_1, w_2, \dots$)를 몇 개나 학습해야 할까? (b 제외)

[힌트 - 개별 뉴런의 구조]




인공신경망과 머신러닝



Quiz 위 인공신경망은 가중치($w_1, w_2, \dots$)를 몇 개나 학습해야 할까? (b 제외)

- 각 뉴런의 연결 선마다 서로 다른 가중치가 존재
 - Input layer $\rightarrow$ 1st hidden layer: $3 \times 3 = \mathbf{9개}$ ($w_{11}, w_{12}, w_{13}, w_{21}, \dots, w_{33}$)
 - 1st hidden layer $\rightarrow$ 2nd hidden layer: $3 \times 2 = \mathbf{6개}$ ($w_{11}, w_{12}, w_{21}, w_{22}, w_{31}, w_{32}$)
 - 2nd hidden layer $\rightarrow$ output layer: $2 \times 1 = \mathbf{2개}$ (w_1, w_2)


인공신경망 학습 방법 = 머신러닝 학습 방법



- 단순 선형 회귀: a , b 값을 바꿔 가면서 가설의 예측치와 학습 데이터 간 오차를 최소화하는 a , b 를 찾음
- 인공 신경망: w 값들을 바꿔 가면서 인공 신경망의 예측치와 학습 데이터 간 오차를 최소화하는 w 를 찾음

→ 선형회귀 가중치 학습법과 기본 원리는 동일

예제 – 필기숫자인식



MNIST 데이터셋

- 미국 국립표준기술연구소(NIST)가 수집한 미국인들의 필기숫자 데이터
- 총 6만 건(숫자 1개당 6천 건)의 데이터

<https://m-alcu.github.io/assets/mnist.png>



손글씨 "5"

배터리 데이터 [0] :


[illegible]

가로 28개 x 세로 28개 픽셀의 밝기 값 (0~255)


모든 점(Pixel)의 수는?

가로 28 × 세로 28 = 784개

필기숫자인식 인공신경망



입력변수
784개



출력변수
10개
(0 ~ 9 중 어느 숫자인가)

딥 러닝


인공신경망을 아주 깊게 쌓으면 훨씬 복잡한 함수를 표현할 수 있다. 그것이 왜 최근에야 가능해졌는가.

인공지능

머신러닝

인공신경망

딥 러닝



더 어려운 문제


- ImageNet 사물 식별 문제
 - 1,400만 건 이상의 이미지 데이터 (평균 이미지 크기 482×418)
 - 20,000개 이상의 카테고리 분류



인공신경망으로 사물을 식별하려면?



입력변수
65,536개
(256×256)



출력변수
(20,000개)


입력이 6만 5천 개, 출력이 2만 개. 얇은 신경망으로는 이 관계를 표현하기 어렵다.

딥 러닝 (Deep Learning)의 개념

심층 인공신경망 = 매우 많은 수의 인공뉴런을 층층이 쌓은 인공신경망
→ 딥 러닝 = 심층 인공신경망 학습 방법



입력변수
65,536개
(256×256)



고양이 0.85

개 0.11

호랑이 0.03


...

출력변수

딥 러닝의 어려움



입력변수
65,536개
(256×256)



학습해야 할 가중치가 너무 많다!

고양이 0.85

개 0.11

호랑이 0.03

...

출력변수
(20,000개)

이 문제를 어떻게 해결했을까?

1

수많은 가중치를 학습시키기 위해 많은 연산이 소요

→ 연산 능력의 향상

2

수많은 가중치를 학습시키기 위해 많은 데이터가 필요

→ 빅데이터 시대의 도래

3

수많은 가중치를 학습시키기 위해 효율적인 계산 방법이 필요

→ 인공지능망 알고리즘의 발전

Moore's Law – The number of transistors on integrated circuit chips (1971-2018)

Moore's law describes the empirical regularity that the number of transistors on integrated circuits doubles approximately every two years. This advancement is important as other aspects of technological progress – such as processing speed or the price of electronic products – are linked to Moore's law.

Source: Wikipedia (https://en.wikipedia.org/wiki/Transistor_count)
The data visualization is available at [OurWorldInData.org](https://www.ourworldindata.org). There you find more visualizations and research on this topic.

Licensed under CC-BY-SA by the author Max Roser


Moore's Law — 집적회로당 트랜지스터 수 (1971-2018), Our World in Data

(1) 연산 능력의 향상 – GPU의 활용

그래픽 처리 장치(Graphics Processing Unit, GPU) → 인공지능망 학습 계산 용도에 적합!




게임 그래픽용으로 개발된 GPU



인공지능망 학습 전용 가속기로 발전

(2) 빅데이터 시대의 도래

- 빅데이터의 3V
 - Volume (양)
 - Variety (다양성)
 - Velocity (속도)



빅데이터 학습 데이터의 구축


- ImageNet 데이터 예시
 - 2006년 Fei-Fei Li 교수가 시작
 - 대규모 데이터베이스 축적 & 수작업으로 건건이 이미지 분류
 - “빅데이터 축적을 통해 이미지 인식 인공지능의 성능을 향상시키자!”




Fei-Fei Li, TED 2015

(3) 새로운 알고리즘의 발전

- 20세기까지의 혁신 기술 - 특허를 통해 보호



라이트 형제 비행기 특허 (1906)



하버의 질소 고정법 특허 (1916)

기술의 공유와 확산

- 21세기의 혁신 기술 – 오픈 소스 기반
 - (예시) GitHub – 프로그램 소스코드 공유 사이트

Learn Git and GitHub without any code!

Using the Hello World guide, you'll create a repository, start a branch, write comments, and open a pull request.

[Read the guide](#) [Start a project](#)

Discover interesting projects and people to populate your personal news feed.

Your news feed helps you keep up with recent activity on repositories you [watch](#) and people you [follow](#).

[Explore GitHub](#)

byoungpilkim / deeplearning Private

Watch 0

Star 0

Fork 0

Code

Issues 0

Pull requests 0

Actions

Projects 0

Security

Insights

Settings

No description, website, or topics provided.

[Manage topics](#)

11 commits

1 branch

0 packages

0 releases

Branch: master

New pull request

Create new file

Upload files

Find file


Clone or download

byoungpilkim no msg Latest commit 4f5c4a6 on 17 Mar 2019

.ipynb_checkpoints	no msg	10 months ago
datasets	no msg	10 months ago
Boston_housing_KR.ipynb	2019-03-10	10 months ago
Census_KR.ipynb	2019-03-10	10 months ago
Estimator_example.ipynb	2019-03-10	10 months ago
IMDB_KR.ipynb	2019-03-10	10 months ago
MNIST_CNN_KR.ipynb	2019-03-10	10 months ago
MNIST_Dense_KR.ipynb	2019-03-10	10 months ago

연구 성과의 공유

- arXiv – 논문 공유 사이트



<https://arxiv.org/>

경진대회를 통한 경쟁

- Netflix Prize – Netflix의 알고리즘을 10% 개선 시 100만 달러
 - 학습 데이터
 - <user, movie, date of grade, grade(1~5)> 100,480,507건
 - 이용자 – 480,189명 (익명), 영화 – 17,770개
 - 이용자당 평균 200개 영화 평가
 - 영화당 평균 5,000 이용자 평가
 - 평가 데이터
 - Quiz set: <user, movie, date of grade, grade(1~5)> 1,408,342건 (순위표)
 - Test set: <user, movie, date of grade> 1,408,789건 (최종 평가)
 - 평가 방법
 - 이용자 평가 결과와의 평균 제곱근 오차 (Root Mean Square Error, RMSE)
- 참가자
 - 186개국 41,305팀 51,051명 참가

Netflix Prize 순위표

[Home](#)
[Rules](#)
[Leaderboard](#)
[Register](#)
[Update](#)
[Submit](#)
[Download](#)


Leaderboard

Display top 100

leaders.

Rank	Team Name	Best Score	% Improvement	Last Submit Time
--	No Grand Prize candidates yet	--	--	--
Grand Prize - RMSE <= 0.8563				
1	BellKor in BigChaos	0.8604	9.56	2008-12-03 16:46:15
Progress Prize - RMSE <= 0.8625				
2	BigChaos	0.8626	9.33	2008-12-04 19:18:27
3	BellKor	0.8630	9.29	2008-12-04 19:25:59
4	PragmaticTheory	0.8638	9.21	2008-11-28 11:46:23
5	Gravity	0.8654	9.04	2008-11-27 21:18:37
6	My Brain and His Chain	0.8668	8.89	2008-09-30 02:19:47
7	Just a guy in a garage	0.8672	8.85	2008-12-07 06:51:12
8	When Gravity and Dinosaurs Unite	0.8675	8.82	2008-10-05 14:16:53
9	Opera Solutions	0.8676	8.81	2008-12-02 22:08:45
10	acmehill	0.8677	8.80	2008-12-05 08:01:00
11	scientist	0.8677	8.80	2008-12-02 01:10:13
12	Ces	0.8711	8.44	2008-08-25 05:00:23
13	Dace	0.8711	8.44	2008-12-07 03:46:04
Progress Prize 2007 - RMSE = 0.8712 - Winning Team: KorBell				
14	KorBell	0.8712	8.43	2007-10-01 23:25:23
15	basho	0.8714	8.41	2008-05-21 22:06:00
16	pengpengzhou	0.8714	8.41	2008-11-05 01:11:13
17	blednotik	0.8717	8.38	2008-11-26 00:12:12


Netflix Prize 결과



3년에 걸친 경쟁 끝에 2009년 BellKor's Pragmatic Chaos 팀이 10.09% 개선으로 100만 달러를 수상


경진대회 사이트

- Kaggle – 다양한 온라인 인공지능 경진대회



The screenshot shows the Kaggle website's 'Competitions' section. The header includes the Kaggle logo, a search bar, and navigation links for Competitions, Datasets, Notebooks, Discussion, and Courses. Below the header, there's a 'Competitions' banner with 'Documentation' and 'InClass' buttons. The main content area lists 16 active competitions, sorted by 'Grouped'. The list includes:

Competition Name	Prize	Teams
Deepfake Detection Challenge (#DFDC)	\$1,000,000	1,041 teams
2019 Data Science Bowl	\$160,000	3,271 teams
TensorFlow 2.0 Question Answering	\$50,000	1,173 teams
Google QUEST Q&A Labeling	\$25,000	932 teams
Peking University/Baidu - Autonomous Driving	\$25,000	833 teams



The screenshot shows the 'COVID19 Global Forecasting (Week 1)' competition page. The header features a banner with the competition title and a description: 'Forecast daily COVID-19 spread in regions around world'. Below the banner, it shows 'Kaggle · 105 teams · 5 days to go'. The navigation bar includes links for Overview, Data, Notebooks, Discussion, Leaderboard, Rules, and a 'Join Competition' button. The 'Overview' section is selected, displaying a table with the following content:

Section	Description
Description	This is one of the two complementary forecasting tasks to predict COVID-19 spread. This task is based on various regions across the world. To start on a single state-level subcomponent, please see the companion forecasting task for California, USA .
Evaluation	
Timeline	
Code Requirements	
Open Scientific Questions	
Background	The White House Office of Science and Technology Policy (OSTP) pulled together a coalition research groups and companies (including Kaggle) to prepare the COVID-19 Open Research Dataset (CORD-19) to attempt to address key open scientific questions on COVID-19 . Those questions are drawn from National Academies of Sciences, Engineering, and Medicine's (NASEM) and the World Health Organization (WHO) .
The Challenge	Kaggle is launching two companion COVID-19 forecasting challenges to help answer a subset of the NASEM/WHO questions . While the challenge involves forecasting confirmed cases and fatalities between March 25 and April 22 by region, the primary goal isn't to produce accurate forecasts. It's to identify factors that appear to impact the transmission rate of COVID-19. You are encouraged to pull in, curate and share data sources that might be helpful. If you find variables that look like they impact the transmission rate, please share your finding in a notebook.

Kaggle – 실시간 순위표 (Leaderboard)

Featured Code Competition

Deepfake Detection Challenge

Identify videos with facial or voice manipulations

#DFDC Deepfake Detection Challenge · 1,041 teams · 3 months to go (2 months to go until merger deadline)

\$1,000,000

Prize Money

[Overview](#) [Data](#) [Notebooks](#) [Discussion](#) [Leaderboard](#) [Rules](#)

[Join Competition](#)

[Public Leaderboard](#) [Private Leaderboard](#)

This leaderboard is calculated with all of the test data. [Raw Data](#) [Refresh](#)

In the money

Gold

Silver

Bronze

#	Team Name	Notebook	Team Members	Score	Entries	Last
1	Vladislav Leketush			0.27295	36	10h
2	JiangJun			0.35735	25	2h
3	Darragh			0.38644	12	3d
4	ttt321			0.39010	22	3d
5	Meisong Zheng			0.40247	26	7h

<https://www.kaggle.com/c/deepfake-detection-challenge/leaderboard>

인공지능 학습 사이클



🔄 새로운 이론은 다시 경진대회에서 검증된다 — 선순환

IMAGENET Challenge

- ImageNet 데이터를 이용하여 사물을 식별하기
 - 2010년 오류율 28%, 2011년 오류율 26%
 - 과연 컴퓨터가 사물을 인식할 수 있을까? 불가능한 도전은 아닐까?



IMAGENET Challenge




Fig. 5. Accuracy for ImageNet challenge with different DL models.

Fig. 5. Accuracy for ImageNet challenge with different DL models — 2012 AlexNet 16.4% → 2015 ResNet-152 3.57% (사람 5%)

→ 사람보다 더 정확하게 사물을 식별!

인공지능 기술 공유 시대의 종말?

- 최근 일부 대규모 언어모형 인공지능은 더 이상 기술 상세정보를 공개하지 않음
 - 영업상의 이익
 - 악의자의 오용 방지
- 예시 – GPT-4 기술 보고서
 - **경쟁 환경(competitive landscape)과 안전에의 함의(safety implications)를 고려하여** 아키텍처(모델 크기 등), 하드웨어, 학습 연산, 데이터세트 구성, 학습방법 등에 대한 추가 세부정보를 포함하지 않는다고 명시

GPT-4 Technical Report

OpenAI*

2 Scope and Limitations of this Technical Report

This report focuses on the capabilities, limitations, and safety properties of GPT-4. GPT-4 is a Transformer-style model [39] pre-trained to predict the next token in a document, using both publicly available data (such as internet data) and data licensed from third-party providers. The model was then fine-tuned using Reinforcement Learning from Human Feedback (RLHF) [40]. Given both the competitive landscape and the safety implications of large-scale models like GPT-4, this report contains no further details about the architecture (including model size), hardware, training compute, dataset construction, training method, or similar.

요약

- 인공신경망이란?
 - 인공 뉴런을 여러 단위로 쌓은 네트워크 = 복잡한 함수의 일종
- 인공 신경망이 하는 일은?
 - = 입력 값에 출력 값을 대응(mapping)시키는 것
- 딥러닝이란?
 - 인공 신경망을 여러 층으로 구성한 것 = 훨씬 더 복잡한 함수를 표현

$$\underbrace{f}_{\text{인공지능}} \left(\underbrace{\hspace{2cm}}_{\text{입력 변수}} \right) = \underbrace{\hspace{2cm}}_{\text{출력 변수}}$$

$$F(x) = \sum_{i=1}^N v_i \varphi(w_i^T x + b_i)$$

미래 인공지능

AI 연구자들은 인간 수준의 기계지능이 언제 올 것이라고 보는가. 전문가 설문조사 결과와 그 해석을 살펴본다.

AI 연구자 2,778명에게 물었다

THOUSANDS OF AI AUTHORS ON THE FUTURE OF AI

PREPRINT

Katja Grace^{*†}
AI Impacts
Berkeley, California
United States
katja@aiimpacts.org

Harlan Stewart[†]
AI Impacts
Berkeley, California
United States

Julia Fabienne Sandkühler[†]
Department of Psychology
University of Bonn
Germany

Stephen Thomas[†]
AI Impacts
Berkeley, California
United States

Ben Weinstein-Raun
Independent
Berkeley, California
United States

Jan Brauner
Department of Computer Science
University of Oxford
United Kingdom

January 2024

ABSTRACT

In the largest survey of its kind, we surveyed 2,778 researchers who had published in top-tier artificial intelligence (AI) venues, asking for their predictions on the pace of AI progress and the nature and impacts of advanced AI systems. The aggregate forecasts give at least a 50% chance of AI systems achieving several milestones by 2028, including autonomously constructing a payment processing site from scratch, creating a song indistinguishable from a new song by a popular musician, and autonomously downloading and fine-tuning a large language model. If science continues undisrupted, the chance of unaided machines outperforming humans in every possible task was estimated at 10% by 2027, and 50% by 2047. The latter estimate is 13 years earlier than that reached in a similar survey we conducted only one year earlier [Grace et al., 2022]. However, the chance of all human occupations becoming fully automatable was forecast to reach 10% by 2037, and 50% as late as 2116 (compared to 2164 in the 2022 survey).

Thousands of AI Authors on the Future of AI


Katja Grace 외 (AI Impacts), Preprint, January 2024

- 최상위 AI 학회에 논문을 발표한 연구자 2,778명 설문
- 2028년까지 다양한 이정표(결제 사이트를 처음부터 자율 구축, 인기 가수 스타일의 신곡 작곡, LLM 미세조정 등)가 달성될 확률 50% 이상
- 모든 과제에서 기계가 인간을 능가할 확률: 2027년 10%, 2047년 50% — 1년 전 조사보다 13년 앞당겨짐
- 모든 직업이 완전 자동화될 확률: 2037년 10%, 2116년 50% (2022년 조사에서는 2164년)

고수준 기계지능 (HLMI)

- 고수준 기계지능 (High-Level Machine Intelligence, HLMI)
 - 정의: 고수준 기계 지능(HLMI)은 인간의 조력을 받지 않는 기계가 모든 과제(task)를 인간 작업자보다 더 저렴하고 더 잘 수행할 수 있을 때 달성됨. 인간이 하는 것이 본질적으로 유리한 과제(예: 배심원으로 인정)는 제외.
 - 도입 여부가 아니라 실현 가능성을 고려할 것
 - 예측 전제: 인간의 과학 활동이 중대한 부정적 혼란(major negative disruption) 없이 계속될 것
- 결과: **2047년** 내 HLMI가 실현될 가능성이 50%로 예상 (50% chance of HLMI by 2047)
 - **2022년 설문조사 결과 2060년 (13년 단축)**
 - **2016년 설문조사 결과 2061년 (14년 단축)**



HLMI 도래 가능성



2023 Aggregate Forecast (빨강) vs 2022 Aggregate Forecast (파랑), 95% 신뢰구간 · 얇은 선은 개별 응답자의 예측 표본


감마 분포 (Gamma Distribution)

- 감마분포
 - 어떤 사건이 θ 의 시간마다 발생하는 경우, k 번째 사건이 일어날 때까지 걸리는 시간을 모델링
 - 각 사건은 상호 독립이라고 가정함
- HLMI 달성 시간 예측 모델링
 - HLMI 달성에 k 개의 기술적 돌파구(breakthrough)가 필요하고, 각 돌파구 달성에 θ 년의 시간이 필요
 - 설문에 응답한 AI 연구자들은 각기 다른 관념을 가지고 있을 것
 - 앞의 그래프는 설문 응답을 통해 각 연구자 내심의 감마분포를 추정, 종합한 결과



AI 전문가 간의 의견 차이

- 2050년까지 90% 이상의 확률로 HLMI가 달성될 것이라는 AI 연구자들
 - **작은 k 값을 가정** - 현재의 AI 모델 구조가 HLMI 달성에 적합하다고 판단 → 적은 추가 혁신이 필요
 - **작은 θ 값을 가정** - (현재의 AI 투자 증가 등으로 인해) 중대한 혁신이 자주 일어날 것으로 전망
- 2100년이 되어도 HLMI가 달성될 확률이 50% 미만이라는 AI 연구자들
 - **큰 k 값을 가정** - 현재의 AI 모델 구조가 HLMI 달성에 적합하지 않다고 판단 → 많은 추가 혁신이 필요
 - **큰 θ 값을 가정** - HLMI 달성에 필요한 중대한 혁신은 빈번하게 일어나지 않을 것으로 판단



왼쪽 위 가파른 곡선 = 낙관적 응답자, 오른쪽 아래 완만한 곡선 = 비관적 응답자

AI 전문가 간의 의견 차이



Possible End of Humanity from AI?

Geoffrey Hinton at MIT Technology Review's EmTech Digital
<https://www.youtube.com/watch?v=sitHS6UDMJc>

"We have to take seriously the possibility that [AI models] get to be smarter than us – which seems quite likely – and they have goals of their own," Hinton said during a standing-room-only event at the conference, which was expected to draw nearly 40,000 attendees over three days.

"They may well develop the goal of taking control – and if they do that, we're in trouble."

[utoronto.ca/news/risks-artificial-intelligence-must-be-considered...](https://www.utoronto.ca/news/risks-artificial-intelligence-must-be-considered...)



AI cannot understand reality | Yann LeCun and Lex Fridman

<https://www.youtube.com/watch?v=RX5N30ulUUA>



Yann LeCun
@ylecun

...


Before we reach Human-Level AI (HLAI), we will have to reach Cat-Level & Dog-Level AI.
We are nowhere near that.
We are still missing something big.
LLM's linguistic abilities notwithstanding.
A house cat has way more common sense and understanding of the world than any LLM.

3:25 AM · Feb 6, 2023 · 807.2K Views

<https://twitter.com/ylecun/status/1622300311573651458>

노동의 완전 자동화


- 노동의 완전 자동화 (Full Automation of Labor, FAOL)
 - 어떤 직업(occupation)이 완전히 자동화될 수 있다는 것은 인간의 조력을 받지 않는 기계가 해당 직업을 인간 작업자보다 더 저렴하고 더 잘 수행할 수 있는 경우를 뜻함. 인간이 하는 것이 본질적으로 유리한 직업의 측면(예: 배심원으로 인정)은 제외.
 - 도입 여부가 아니라 실현 가능성을 고려할 것
 - ‘노동의 완전 자동화’는 모든 직업이 완전히 자동화될 수 있는 때를 뜻함. 즉, 어떤 직업에 있어서도 기계가 인간 작업자보다 더 저렴하고 더 잘 작업을 수행할 수 있는 때를 지칭함.
- 특정 직업의 완전 자동화 가능 시점 예상
 - 설문 대상: 트럭 운전사, 외과의사, 소매점 판매원, AI 연구자



과제(task)·직업(job)별 50% 달성 예상 연도

노동의 완전 자동화 도래 가능성


- 노동의 완전 자동화 발생 확률이 50%가 되는 시점 예측치는 **2116년**
 - 2022년 설문조사 결과 2164년 (48년 단축)



고수준 기계지능(HLMI) vs 노동 완전자동화(FAOL)

- FAOL 확률 50% 예측은 HLMI 확률 50% 예측보다 60년 이상 늦음
 - 2016, 2022, 2023년에서 일관되게 존재하는 차이
- 왜 이러한 차이가 존재하는가?
 - FAOL과 HLMI는 유사한 것 – HLMI가 달성된다면 조만간 FAOL이 달성될 수 있어야 함
 - 예측의 차이는 프레임링 효과(framing effect) 때문이라고 볼 수 있음
 - “과제(task)” vs “직업(occupation)”의 차이 때문이라고도 볼 여지가 있음
 - 답변자들이 질문상의 명시적 요건(도입 여부가 아니라 실현 가능성을 고려할 것)에도 불구하고, 양자를 달리 해석하였을 수도 있음
 - FAOL은 물리적 조작을 포함, HLMI는 물리적 조작을 포함하지 않는 것으로 해석
 - FAOL은 adoption을 포함, HLMI는 adoption을 포함하지 않는 것으로 해석

인간 지능의 위계와 자동화



과거에는 단순 노동부터 자동화될 것으로 보았지만, 생성형 AI는 창작과 지식 노동부터 파고들고 있다.

기술 예측의 어려움

The Americans have need of the telephone, but we do not. We have plenty of messenger boys.
Sir William Preece, chief engineer of the British Post Office, 1876

William Preece (영국 체신청 수석 엔지니어), 1876
<https://www.quotesplanet.com/telephone-quotes>



"I think that there is a world market for maybe five computers."
- remark attributed to Thomas J. Watson, chairman of IBM, 1943

Thomas J. Watson (IBM 회장), 1943
scientificamerican.com/article/pogue-all-time-worst-tech-predictions/

“

*Man is still the most extraordinary computer
of all.*



John F. Kennedy

