

대규모 언어모델과 기반모델

컴퓨터는 어떻게 말을 숫자로 바꾸고, 그 숫자로 다음 단어를 맞히게 되었나. 단어 임베딩, 트랜스포머, 사후학습, ChatGPT, 그리고 범용·멀티모달 기반모델을 차례로 살펴본다.

2026. 9. 10.

김병필 · KAIST 기술경영전문대학원

1

자연어 처리와 단어
임베딩
말을 숫자로 바꾸기

2

시퀀스 데이터와
순환 신경망
앞 단어의 기억을
넘기기

3

언어모델과
트랜스포머
다음 단어 예측하기

4

GPT와 스케일링
법칙
크게 만들수록 잘한다

5

사후학습과
ChatGPT
사람 피드백으로
조정하기

6

기반모델
하나의 모델, 수많은
용도

7

범용·멀티모달
기반모델
글을 넘어 이미지·
소리로

자연어 처리와 단어 임베딩

단어를 숫자로 바꾸는 방법. 등장 횟수를 세는 방법에서 단어의 뜻을 좌표로 나타내는 방법으로.

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머

4 GPT와 스케일링 법칙

5 사후학습과 ChatGPT

6 기반모델

7 범용·멀티모달 기반모델

1강에서 본 "인공지능 = 함수"를 떠올리자. 입력이 문장이라면, 함수에 넣기 전에 문장을 먼저 숫자로 바꿔야 한다.

자연어 처리 기술

1

두 종류의 언어

- 프로그래밍 언어 (Programming Language) — 컴퓨터를 위해 만든 말
- 자연어 (Natural Language) — 사람이 쓰는 말

2

자연어 처리 (NLP)

- 컴퓨터를 이용하여 유용한 작업을 수행하기 위해 자연어를 처리·이해하는 방법에 관한 연구
- 컴퓨터 공학의 고전적 주제 — 1954년 조지타운 대학과 IBM이 러시아어 60문장을 영어로 기계번역
- 그러나 2010년까지 기계번역은 인간 수준에 현저히 못 미침

3

딥러닝의 적용 (2010~)

- 음성인식 과제에서 딥러닝이 놀라운 성능 향상을 보임
- Amazon Alexa, Google Assistant, Apple Siri 등 상업 시스템이 딥러닝 방식을 채택
- 음성 인식, 기계 번역, 대화(챗봇)로 확산

2010년대 중반의 자연어 처리 — 언어를 “이해”하지 못하는 인공지능

“Machines that truly understand language would be incredibly useful. **But we don't know how to build them.**”

– Will Knight, MIT Technology Review (2016)

문법 분석 — 되는 것

품사 분류, 구문 분석

언어학자 수준까지 분석 가능

의미 분석 — 안 되는 것

Meaning: 중의·함의·은유·반의

Context: 문맥·맥락·상황

Reasoning: 상식(common sense)이 필요




“맥도날드가 아닌 패스트푸드점을 찾아줘” → 맥도날드 3곳 (Siri, 2010년대 중반)

인공신경망에 텍스트 입력하기

- 단어를 표현하는 가장 단순한 방법 = 세어 보기 (count-based approach)
 - 자주 사용되는 단어 사전(vocabulary)을 구축 — 영어라면 a로 시작하는 단어부터 z로 시작하는 단어까지 알파벳 순으로
 - 이진 표현법: 단어 하나 = 사전에서 그 단어의 자리만 1, 나머지는 모두 0인 숫자 열
 - 문서 전체 = 등장한 단어들의 숫자 열을 모두 합친 것 (등장 여부 0/1 또는 등장 횟수)

aardvark	abandon	abbey	...	zoo	zucchini
$\begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 0 \\ 1 \\ \vdots \\ 0 \\ 0 \end{pmatrix}$	...	$\begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{pmatrix}$

사전의 단어 수(예: 5만)만큼
긴 숫자 열.
자기 자리만 1, 나머지는 0



문서(메일) 하나 = 등장한 단어들의 벡터를 모두 합친 것
→ 사전의 각 자리에 등장 여부(0/1)나 횟수가 담긴 문서
벡터


이 숫자 열은 “사전의 몇 번째 단어인가”만 말해 줄 뿐, 단어의 뜻은 담지 않는다.

간단한 스팸 메일 분류기

사전	등장?
aardvark	0
...	...
about	1
...	...
call	0
...	...
prince	1
...	...
nigerian	1
...	...
zucchini	0

입력변수

메일 한 통의 문서 벡터
= 사전의 단어 수만큼



출력변수
스팸 여부 [0 / 1]

1장의 필기숫자 인식과 같은 구조다. 입력이 픽셀 784개에서 "단어 수만큼"으로 바뀌었을 뿐이다.

더 나은 방법은 없을까?

- 세어 보기(count-based) 방식의 문제점 — 단어 하나마다 단어 사전 개수(수만~수십만)만큼의 숫자 열이 필요. 그중 1은 단 하나, 나머지는 전부 0 → **공간의 낭비**
- 단어의 특징을 숫자로 표현하기 — 단어의 특성을 나타내는 **변수**를 정하고, 단어마다 값을 매긴다

변수
몇 개?




특징	Man	Woman	King	Queen	Apple	Orange
성별	-1	1	-0.95	0.97	0.00	0.01
왕족	0.01	0.02	0.93	0.95	-0.01	0.00
나이	0.03	0.02	0.7	0.69	0.03	-0.02
음식	0.04	0.01	0.02	0.01	0.95	0.97
...	...	...	...	...	...	...

- 몇 개의 변수가 있으면 세상의 각 단어를 잘 구분할 수 있을까?
→ **연구자들은 300개 정도의 변수면 적절하다는 것을 발견**
- 다만, 누가 각 변수를 지정하고, 값을 어떻게 채울까?

단어 임베딩 (Word Embedding)

- 인공신경망이 스스로 단어의 특징을 학습한 결과 — 축의 이름은 없지만, 숫자 300개가 단어의 “뜻”을 담는다

→ 각각의 단어를 300차원의 공간에 좌표로 찍어 놓은 것!



300차원을 2차원으로 눌러서 그린 지도 — 비슷한 뜻의 단어는 가까이 모인다 (Andrew Ng, Coursera)

단어 임베딩의 특징





Figure 4. Embeddings can produce remarkable analogies.


Figure 4. Embeddings can produce remarkable analogies — 성별, 시제, 나라-수도 관계가 같은 “방향”으로 나타난다 (Google ML Crash Course)

"king" - "man" + "woman" = "queen"



단어가 좌표가 되면 단어끼리 더하고 뺄 수 있다. "왕"에서 "남자"를 빼고 "여자"를 더하면 "여왕" 근처에 도착한다.


사랑 + 이별 = ?



A screenshot of a word2vec web application interface. The background is a dark, blurry image with warm, orange and yellow bokeh lights. On the left, there is a yellow circle with a black question mark. To its right is a white input box containing the text '사랑+이별'. Below this is a section titled 'QUERY' in bold. Under 'QUERY', there are two white boxes: the first contains '+사랑/Noun' and the second contains '+이별/Noun'. Below the 'QUERY' section is a section titled 'RESULT' in bold. Under 'RESULT', there is a white box containing three red question marks '???'.

한국어 임베딩에서 "사랑 + 이별"을 계산하면 어떤 단어 근처에 도착할까? (word2vec.kr)

사랑 + 이별 = 추억



A screenshot of the word2vec.kr search interface. The background is a dark, blurry image with warm, bokeh-like light spots. On the left, there is a yellow circle with a white question mark. The main interface is a white rectangular box with a light blue border. At the top of this box is a search input field containing the text '사랑+이별'. Below the input field, the word 'QUERY' is displayed in bold. Underneath 'QUERY', there are two small rectangular buttons: the first contains '+사랑/Noun' and the second contains '+이별/Noun'. Below these buttons, the word 'RESULT' is displayed in bold. Underneath 'RESULT', there is a single rectangular box containing the text '추억/Noun'.

결과: 추억 — 단어의 뜻을 좌표로 찍어 두면 이런 “연산”이 가능해진다 (word2vec.kr)

Word2Vec 특허 (US 9,037,464 B1)

Efficient Estimation of Word Representations in Vector Space

Tomas Mikolov
Google Inc., Mountain View, CA
tmikolov@google.com

Kai Chen
Google Inc., Mountain View, CA
kaichen@google.com

Greg Corrado
Google Inc., Mountain View, CA
gcorrado@google.com

Jeffrey Dean
Google Inc., Mountain View, CA
jeff@google.com


Abstract

We propose two novel model architectures for computing continuous vector representations of words from very large data sets. The quality of these representations is measured in a word similarity task, and the results are compared to the previously best performing techniques based on different types of neural networks. We observe large improvements in accuracy at much lower computational cost, i.e. it takes less than a day to learn high quality word vectors from a 1.6 billion words data set. Furthermore, we show that these vectors provide state-of-the-art performance on our test set for measuring syntactic and semantic word similarities.

논문: Mikolov, Chen, Corrado, Dean (Google), "Efficient Estimation of Word Representations in Vector Space" (2013)


(12) United States Patent Mikolov et al.

- (54) **COMPUTING NUMERIC REPRESENTATIONS OF WORDS IN A HIGH-DIMENSIONAL SPACE**
- (71) Applicant: **Google Inc.**, Mountain View, CA (US)
- (72) Inventors: **Tomas Mikolov**, Jersey City, NJ (US);
Kai Chen, San Bruno, CA (US);
Gregory S. Corrado, San Francisco, CA (US); **Jeffrey A. Dean**, Palo Alto, CA (US)



같은 발명을 논문과 특허로 동시에 — "Computing numeric representations of words in a high-dimensional space" (2015 등록)

단어 의미의 변화



연도별로 따로 학습한 임베딩 — apple은 과일에서 IT 기업으로, amazon은 정글에서 온라인 서점으로 이동한다 (Yao et al. 2018)

임베딩은 “사전에 적힌 뜻”이 아니라 “그 시기 사람들이 그 단어를 어떻게 썼는가”를 담는다.

시퀀스 데이터와 순환 신경망

문장은 단어의 “순서”다. 앞에서 본 단어의 기억을 옆으로 넘겨 가며 읽는 신경망, 순환 신경망 (RNN).

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머

4 GPT와 스케일링 법칙

5 사후학습과 ChatGPT

6 기반모델

7 범용·멀티모달 기반모델

앞 섹션의 스팸 분류기는 단어의 순서를 무시하고 “있다/없다”만 세었다. 그러면 “개가 사람을 물었다”와 “사람이 개를 물었다”가 같은 문장이 된다.

시퀀스 데이터


Examples of sequence data

Speech recognition



"The quick brown fox jumped
over the lazy dog."

Music generation



Sentiment classification

"There is nothing to like
in this movie."



DNA sequence analysis

AGCCCCTGTGAGGAACTAG



AGCCCCTGTGAGGAACTAG

Machine translation

Voulez-vous chanter avec
moi?



Do you want to sing with
me?

Video activity recognition



Running

Name entity recognition

Yesterday, Harry Potter
met Hermione Granger.




Yesterday, **Harry Potter**
met **Hermione Granger**.
Andrew Ng


입력이나 출력이 "순서 있는 열"인 문제들 — 음성, 음악, 문장, DNA, 영상 (Andrew Ng, Coursera)

Intuition — 보이지 않는 “상태”가 있다

- 잠재 변수 (Latent Variable, Hidden Variable)
 - “관측되는 현상은 관측되지 않는 잠재 변수의 발현”
 - 잠재 변수: 기상의 상황 · 관측 현상: 기온, 습도, 구름량, ...
- 우리는 잠재 변수를 곧바로 알 수 없음
 - 관측 값을 이용하여 잠재 변수를 추정
 - 새로운 현상이 관측되면 기존 잠재 변수를 업데이트
- → 이 숨은 상태(hidden variable)가 “지금까지 본 것”을 요약한다




순환 신경망 (RNN)의 기본 개념



<t-1> 단계 상태 정보(Hidden Variable)로 <t> 단계 상태 정보 업데이트


RNN 모델 - 영화평 읽기

문제 - 다음 영화평은 긍정적인가? (0 / 1 이진분류) "This movie is a true masterpiece."



- 단어를 (임베딩 숫자로 바꿔) **하나씩 순서대로** 넣는다
- 각 단계의 **상태(기억)**는 "이전 단계의 상태 + 지금 들어온 단어"로 갱신된다 — $\langle t-1 \rangle$ 단계 상태 정보로 $\langle t \rangle$ 단계 상태 정보를 업데이트
- 그래서 마지막 상태에는 문장 전체의 정보가 **순서대로 쌓여** 있다


예제 (Many-to-One) – 감성 인식



- **마지막 단계만 결과 값 출력** — 문장을 끝까지 읽은 뒤 “긍정(1) / 부정(0)”을 판단
- 학습 방법은 1강과 같다: (영화평, 정답) 쌍을 잔뜩 주고, 예측 오차를 줄이는 방향으로 가중치를 조금씩 고친다

여러 개(단어)가 들어가서 하나(판정)가 나온다고 해서 **many-to-one**. 반대로 하나가 들어가서 여러 개가 나오는 **one-to-many**도 가능하다 → 다음 장

예제 (One-to-Many) – 음악 작곡



- 이전 단계 예측 값을 다음 단계 입력으로 활용 — 시작 신호 하나만 주면 음이 차례로 이어진다
- 수많은 악보로 “다음 음”을 맞히도록 학습한 결과
- → 이 구조가 곧 뒤에서 볼 “다음 단어 예측” 언어모델의 원형


ITERATION 2000

▶ AI Composer — 학습 반복 횟수에 따라 달라지는 작곡



▶ 베토벤 10번 교향곡 — AI가 완성한 미완성 교향곡

예제 (Many-to-Many) – 기계 번역




- 앞부분 = 인코더: 입력 문장을 단어 순서대로 읽어, 마지막 상태에 문장 전체의 정보를 담는다
- 중간 = 문맥 벡터(context vector): 인코더가 남긴 숫자 배열. 뒷부분에 넘겨주는 유일한 정보
- 뒷부분 = 디코더: 문맥 벡터에서 출발해, 작곡 예제처럼 단어를 하나씩 이어 쓴다

질문 — 어떤 문장의 정보를 모두 담으려면 변수가 몇 개여야 할까?

실제 seq2seq 모델에서는 숫자 수천 개다. 초기 seq2seq(Sutskever et al. 2014)는 문장 하나를 8,000개의 숫자로 표현했다. 단어 하나를 담는 임베딩(300개)보다 훨씬 크다.

기계 번역 – Google Neural Machine Translation (2016)

- 종전 기술 – 규칙 기반 접근법
 - 문장을 여러 부분으로 쪼개고, 규칙을 적용하여 다른 언어로 옮긴 다음, 다시 조합
- 2016년 9월 Google Neural Machine Translation (GNMT) 도입
 - **입력 문장의 각 단어를 순차적으로 순환신경망에 입력**
 - 순환신경망의 은닉 계층이 단어의 순서를 반영한 정보를 기억
 - 그 정보를 이용하여 다른 언어의 문장을 생성 — 입력 문장에서 곧바로 번역문으로



GNMT 구조 (Wu et al. 2016) — 인코더·디코더 모두 순환 신경망을 8층씩 쌓은 것. 앞 장의 도식을 실제 규모로 키운 셈

언어모델과 트랜스포머

다음 단어 하나를 맞히는 것. 그것이 언어모델의 전부이고, 트랜스포머는 그 일을 아주 잘하는 구조다.

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머

4 GPT와 스케일링 법칙

5 사후학습과 ChatGPT

6 기반모델

7 범용·멀티모달 기반모델

작곡 예제에서 “다음 음”을 이어 붙였듯, 이번에는 “다음 단어”를 이어 붙인다.

언어모델 (Language Model)

사람이 말했을 법한 문장은?

Jane went to the store.	○	문법 이해
store to Jane went the.	×	
Jane went store.	×	
Jane goed to the store.	×	어형 변화
The store went to Jane.	×	의미 분석
The food truck went to Jane.	○	의미 분석의 예외

언어 모델 = $P(\text{text})$ — “이 문장이 나올 법한 정도”를 확률로 매기는 함수

언어모델의 원리

질문 - 다음에 올 단어는?

Jane had a headache yesterday. She went to the _____.

Pharmacy

확률 ↑↑

Store

확률 ↑

Banana

확률 ↓↓

앞 문장(두통)까지 읽고 있어야 "pharmacy"에 가장 높은 확률을 줄 수 있다.

언어모델의 핵심 = 다음 단어 예측하기

- 조건부 확률의 연쇄 법칙 (chain rule)


$$P(\text{"I love you"}) = P(\text{"I"}) \times P(\text{"love"} \mid \text{"I"}) \times P(\text{"you"} \mid \text{"I love"})$$

- $P(\text{"I"})$ – 첫 단어가 "I"일 확률
- $P(\text{"love"} \mid \text{"I"})$ – "I" 다음에 "love"가 올 확률
- $P(\text{"you"} \mid \text{"I love"})$ – "I love" 다음에 "you"가 올 확률

언어모델의 구현 — 주어진 단어 배열 다음에 등장할 단어를 예측하도록 인공신경망을 학습시키면 된다. 문장의 확률은 "다음 단어 확률"의 곱으로 얻어진다.



언어 모델을 이용한 작문

→ 다음에 올 단어 예측하기 — 예측한 단어를 다시 입력으로 넣어 이어 쓴다



작곡 예제의 "다음 음"이 "다음 단어"로 바뀌었을 뿐, 구조는 같다.

RNN 언어모델의 한계 – Long-Term Dependency 문제



문제 – 다음에 올 단어는?

I grew up in France. I speak fluent ____.

→ 바로 앞에 "France"가 있으니 쉽다

문제 – 다음에 올 단어는?

I grew up in France ... (수십 문장) ... I speak fluent ____.

→ "France"가 너무 멀리 있다

→ 문장이 길어지면 상태 h_t 가 멀리 떨어진 정보를 반영하지 못하는 한계


Attention 기법 (2014) — 어디를 볼지 정하기

- Long-Term Dependency 문제의 해결 — 멀리 있어도 “관련 있는 단어”를 직접 찾아본다

The animal didn't cross the street because it was too tired.
L'animal n'a pas traversé la rue parce qu'il était trop fatigué.


The animal didn't cross the street because it was too wide.
L'animal n'a pas traversé la rue parce qu'elle était trop large.

“it”이 animal인지 street인지에 따라 프랑스어 번역(il / elle)이 달라진다




번역 모델이 “it”을 처리할 때 주목한 단어 — 왼쪽은 animal, 오른쪽은 street

Attention 기법 (2014) — 입력된 단어 중 어디를 주목할지 학습




디코더가 단어를 하나 쓸 때마다 인코더의 어느 단어를 볼지(attention) 정한다 — 문맥 벡터 하나에 다 담지 않아도 된다



ATTENTION Map — 밝을수록 강하게 주목

Google – Transformer 모델 (2017)




- 순환 신경망(RNN)의 두 가지 한계
 - 단어를 순서대로 하나씩 처리해야 하므로 **병렬 처리가 불가능**
 - 멀리 떨어진 단어 사이의 관계(전역 의존성)를 학습하기 어려움
- Transformer: 순환 구조를 버리고 **attention만으로** 인코더·디코더를 만든 모델 —
"Attention Is All You Need" (Vaswani et al. 2017)

→ **Multi-headed Self Attention** 기법을 활용하여 기존 Seq2Seq 모델 개선

Transformer 모델 특허

	(19) 대한민국특허청(KR)	(45) 공고일자 2020년11월17일
	(12) 등록특허공보(B1)	(11) 등록번호 10-2180002
		(24) 등록일자 2020년11월11일
(51) 국제특허분류(Int. Cl.)	(73) 특허권자	
G06N 3/04 (2006.01) G06N 3/08 (2006.01)	구글 엘엘씨	
(52) CPC특허분류	미국 캘리포니아 마운틴 뷰 엠피시어터 파크웨이 1600 (우:94043)	
G06N 3/0454 (2013.01)	(72) 발명자	
G06N 3/08 (2013.01)	사즈엘 노암 엠.	
(21) 출원번호 10-2019-7019186	미국 캘리포니아 마운틴 뷰 엠피시어터 파크웨이 1600 (우:94043)	
(22) 출원일자(국제) 2018년05월23일	코메즈 에이던 니콜라스	
심사청구일자 2019년07월02일	미국 캘리포니아 마운틴 뷰 엠피시어터 파크웨이 1600 (우:94043)	
(85) 번역문제출일자 2019년07월02일	(74) 대리인	
(65) 공개번호 10-2019-0089980	박장원	
(43) 공개일자 2019년07월31일		
(86) 국제출원번호 PCT/US2018/034224		
(87) 국제공개번호 WO 2018/217948		
국제공개일자 2018년11월29일		
(30) 우선권주장		
62/510,256 2017년05월23일 미국(US)		
62/541,594 2017년08월04일 미국(US)		
(56) 선행기술조사문헌		
KR1020150037986 A		
전체 청구항 수 : 총 30 항		심사관 : 박상현
(54) 발명의 명칭 어텐션-기반의 시퀀스 변환 신경망		
(57) 요약		
방법들, 시스템들 및 디바이스들은 입력 시퀀스로부터 출력 시퀀스를 생성하기 위한 컴퓨터 저장 매체 상에 인코딩된 컴퓨터 프로그램을 포함한다. 일 양태에서, 시스템들 중 하나는 입력 시퀀스를 수신하고 네트워크 입력의 인코딩된 표현을 생성하도록 구성된 인코더 신경망과, 상기 인코더 신경망은 하나 이상의 인코더 서브네트워크의 시퀀스를 포함하고, 각 인코더 서브네트워크는 입력 위치들 각각에 대한 개별 인코더 서브네트워크 입력을 수신하여 입력 위치들 각각에 대한 개별 서브네트워크 출력을 생성하도록 구성되고, 그리고 각 인코더 서브네트워크는 입력 위치들 각각에 대한 서브네트워크 입력을 수신하여, 상기 입력 순서의 각각의 특정 입력 위치에 대해, 상기 특정 입력 위치에서 상기 인코더 서브네트워크 입력으로부터 도출된 하나 이상의 쿼리를 사용하여 상기 인코더 서브네트워크 입력들에 어텐션 메커니즘을 적용하는 인코더 셀프-어텐션 서브-계층을 포함한다.		

등록특허 10-2180002 “어텐션-기반의 시퀀스 변환 신경망” (Google LLC, 2020년 등록)



도면 1 — 논문의 그림이 특허 도면이 되었다

등록특허 10-2180002 청구항 1

청구항 1

하나 이상의 컴퓨터 및 상기 하나 이상의 컴퓨터에 의해 실행될 때 하나 이상의 컴퓨터로 하여금 입력 순서로 복수의 입력 위치 각각에서 개별 네트워크 입력을 갖는 입력 시퀀스를, 출력 순서로 복수의 출력 위치 각각에서 개별 네트워크 출력을 갖는 출력 시퀀스로 변환하는 시퀀스 변환 신경망을 구현하게 하는 명령을 저장하는 하나 이상의 저장 디바이스를 포함하는 시스템으로서, 상기 시퀀스 변환 신경망은,

입력 시퀀스를 수신하여 그 입력 시퀀스에서 각각의 네트워크 입력의 개별 인코딩된 표현을 생성하도록 구성된 인코더 신경망과, 상기 인코더 신경망은 하나 이상의 인코더 서브네트워크의 시퀀스를 포함하고, 각 인코더 서브네트워크는 복수의 입력 위치 각각에 대한 개별 인코더 서브네트워크 입력을 수신하여 복수의 입력 위치 각각에 대한 개별 서브네트워크 출력을 생성하도록 구성되고, 각 인코더 서브네트워크는,

복수의 입력 위치 각각에 대한 서브네트워크 입력을 수신하여, 입력 순서로 각 특정 입력 위치에 대해:

복수의 입력 위치에서 인코더 서브네트워크 입력들에 대해 셀프-어텐션(self-attention) 메커니즘을 적용하여 특정 입력 위치에 대한 개별 출력을 생성하도록 구성된 인코더 셀프-어텐션 서브-계층을 포함하고, 상기 셀프-어텐션 메커니즘을 적용하는 것은 특정 입력 위치에서 서브네트워크 입력으로부터 쿼리를 결정하고, 복수의 입력 위치에서 서브 네트워크 입력들로부터 도출된 키들을 결정하고, 복수의 입력 위치에서 서브 네트워크 입력들로부터 도출된 값들을 결정하고, 상기 결정된 쿼리, 키들 및 값들을 사용하여 특정 입력 위치에 대한 개별 출력을 생성하는 것을 포함하며; 그리고

인코딩된 표현을 수신하여 출력 시퀀스를 생성하도록 구성된 디코더 신경망을 포함하는 것을 특징으로 하는 시스템.

청구항이 잡아낸 핵심 요소

- 입력 시퀀스를 받아 표현을 만드는 **인코더 신경망**
- 각 입력 위치에 대해 **셀프-어텐션**을 적용하는 서브네트워크
- 입력으로부터 **쿼리·키·값**을 만들어 출력을 계산
- 인코딩된 표현에서 출력 시퀀스를 생성하는 **디코더 신경망**

특허는 “아이디어”가 아니라 이렇게 요소들의 조합으로 정의된 “구성”을 보호한다. 다음 섹션의 디코더 특허는 이 청구항에서 디코더 부분만 떼어 낸 것이다.

“셀프-어텐션”에 대한 직관적 이해

Q

Query

“누구 이런 정보 가진 사람?” — 각 단어가 다른 단어들에게 던지는 질문

K

Key


“나는 이런 정보 가졌어!” — 각 단어가 내거는 이름표

V

Value

만약 (Query, Key) 매칭이 잘 된다면 “다음 계층으로 이 정보를 넘겨줘” — 실제로 전달되는 내용

구조 — 모든 단어를 Query, Key, Value로 변환한다. 모든 Query에 대해 Key와 매칭시켜서, 잘 매칭이 되면 Value 값을 다음 계층으로 전달한다.



문장 안의 모든 단어가 서로 매칭 대상이 된다 — 그래서 “셀프(self)” 어텐션


“셀프-어텐션”의 장점 — 더 빨리 배우고, 더 잘 번역한다

- 손쉽게 병렬처리 가능

- 순환 신경망의 순차적인 특성이 없음 → 긴 학습·추론 시간, 높은 자원 사용 문제 완화


- 전역 의존성 문제 해결

- 먼 위치들 사이의 의존성을 효과적으로 학습
- 학습이 더 쉽고 빠르면서도 기계번역에서 최고 성능(state-of-the-art) 달성



BLEU scores (higher is better) of single models on the standard WMT newstest2014 English to German translation benchmark.

English → German



BLEU scores (higher is better) of single models on the standard WMT newstest2014 English to French translation benchmark.


English → French

<https://ai.googleblog.com/2017/08/transformer-novel-neural-network.html>

AlphaFold – “셀프-어텐션” 신경망의 활용

Fig. 3: Architectural details.

From: [Highly accurate protein structure prediction with AlphaFold](#)



Jumper et al. (2021), Nature — 단백질 서열을 “문장”처럼 읽는 attention 구조로 3차원 구조를 예측 (2024년 노벨 화학상)

언어를 위해 만든 구조가 언어 밖(단백질, 이미지, 소리)에도 적용된다

GPT와 스케일링 법칙

트랜스포머의 디코더만 떼어 내어 다음 단어 예측에 집중한 모델, GPT. 그것을 100배 키웠을 때 무엇이 달라졌는가.

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머


4 GPT와 스케일링 법칙

5 사후학습과 ChatGPT


6 기반모델

7 범용·멀티모달 기반모델

GPT = Transformer 모델의 디코더 부분



Transformer (2017) — 인코더 스택 + 디코더 스택



GPT — 디코더만 여러 층 쌓은 구조 (decoder-only)

- **GPT-1 (2018. 6)** — “Improving Language Understanding by Generative Pre-Training” (OpenAI). 학습 과제는 단 하나, **다음 단어 예측**(generative pre-training)
- **GPT-2 (2019) / GPT-3 (2020)** — 같은 구조를 점점 더 크게 확장

등록특허 10-2448389 – 디코더 특허

청구항 1

하나 이상의 컴퓨터 및 하나 이상의 컴퓨터에 의해 실행될 때 하나 이상의 컴퓨터로 하여금 입력 순서로 복수의 입력 위치 각각에서 개별 네트워크 입력을 갖는 입력 시퀀스를, 출력 순서로 복수의 출력 위치 각각에서 개별 네트워크 출력을 갖는 출력 시퀀스로 변환하기 위한 시퀀스 변환 신경망을 구현하게 하는 명령을 저장하는 하나 이상의 저장 디바이스를 포함하는 시스템으로서, 상기 시퀀스 변환 신경망은,

디코더 입력을 수신하고 그 디코더 입력을 처리하여 출력 시퀀스를 생성하도록 구성된 디코더 신경망과, 상기 디코더 입력은 입력 시퀀스에서 각 네트워크 입력의 개별 표현을 포함하고, 상기 디코더 신경망은 하나 이상의 디코더 서브 네트워크의 시퀀스를 포함하고,

각 디코더 서브 네트워크는 복수의 생성 시간 단계 각각에서, (i) 현재 생성 시간 단계에 대응하는 현재 출력 위치 이전의 특정 출력 위치 각각에 대해 개별 디코더 서브 네트워크 입력을 수신하여, (ii) 현재 출력 위치 이전의 특정 출력 위치 각각에 대해 개별 디코더 서브 네트워크 출력을 생성하도록 구성되고, 상기 각 디코더 서브 네트워크는:


디코더 셀프-어텐션(self-attention) 서브-계층을 포함하여, 각 생성 시간 단계에서, 현재 출력 위치 이전의 특정 출력 위치 각각에 대한 디코더 서브 네트워크 입력을 수신하고, 그리고 특정 출력 위치 각각에 대해:

특정 출력 위치에 대한 개별 업데이트된 표현을 생성하도록 현재 출력 위치 이전의 특정 출력 위치들에서 디코더 서브 네트워크 입력들에 대해 셀프-어텐션 메커니즘을 적용하도록 구성되고, 상기 셀프-어텐션 메커니즘을 적용하는 것은 특정 출력 위치들에서 디코더 서브 네트워크 입력들로부터 쿼리를 결정하고, 특정 출력 위치들에서 디코더 서브 네트워크 입력들로부터 도출된 키들을 결정하고, 특정 출력 위치들에서 디코더 서브 네트워크 입력들로부터 도출된 값들을 결정하고 그리고 결정된 쿼리, 키들 및 값들을 사용하여 특정 출력 위치에 대한 개별 업데이트된 표현을 생성하는 것을 포함하는 것을 특징으로 하는 시스템.

앞 섹션 특허(10-2180002)와의 관계

- 같은 출원에서 갈라져 나온 특허 — 인코더 없이 **디코더 신경망**만으로 구성된 시퀀스 변환 신경망을 청구
- 디코더의 각 층은 **디코더 셀프-어텐션** 서브계층을 포함 — 이미 생성한 출력 위치들만 참조
- GPT 계열이 쓰는 구조가 바로 이 청구항의 구성

GPT-2 (2019. 2)



- “Better Language Models and Their Implications” (OpenAI, 2019. 2)
- 파라미터 15억 개, 웹 문서 40GB(약 800만 페이지)로 다음 단어 예측만 학습
- 과제별로 따로 학습하지 않았는데도 읽기 이해, 번역, 질의응답, 요약을 어느 정도 수행

GPT-2로 생성한 문장

SYSTEM PROMPT (HUMAN-WRITTEN)

A train carriage containing controlled nuclear materials was stolen in Cincinnati today. Its whereabouts are unknown.

MODEL COMPLETION (MACHINE-WRITTEN, FIRST TRY)

The incident occurred on the downtown train line, which runs from Covington and Ashland stations.

In an email to Ohio news outlets, the U.S. Department of Energy said it is working with the Federal Railroad Administration to find the thief.

“The theft of this nuclear material will have significant negative consequences on public and environmental health, our workforce and the economy of our nation,” said Tom Hicks, the U.S. Energy Secretary, in a statement. “Our top priority is to secure the theft and ensure it doesn’t happen again.”

The stolen material was taken from the University of Cincinnati’s Research Triangle Park nuclear research site, according to a news release from Department officials.

The Nuclear Regulatory Commission did not immediately release any information.

기사 첫 문장(사람이 작성) → 이어 쓴 기사(GPT-2, 첫 시도)

자연스러운 가짜 뉴스 생성 가능

가짜 뉴스 활용 우려

Fear of fake news: Why Elon Musk's AI group refused to reveal its software

BY IANS | FEB 15, 2019, 01.43 PM IST

Post a Comment

SAN FRANCISCO: Elon Musk-founded non-profit [Artificial Intelligence](#) (AI) research group [OpenAI](#) has decided not to reveal its new AI software in detail, fearing the AI-based model can be misused by bad actors in creating real-looking [fake news](#).

Dubbed as "GPT2", the AI-based automated text generator can produce fake news articles and abusive posts after being fed with a few pieces of data.

"We've trained a large-scale unsupervised language model which generates coherent paragraphs of text and performs rudimentary reading comprehension, machine translation, question answering and summarization - "all without task-specific training," OpenAI said in a blog post late on Thursday.

Trained on a data set of eight million web pages, "GPT2" can adapt to the style and the content of the text you feed it.

OpenAI said the AI model is so good and the risk of malicious use is so high that it is not releasing the full research to the public.



Elon Musk

Related

- [Elon Musk puts price tag on ticket to Moon and Mars, says it'll cost less than \\$100,000](#)
- [In a first, WhatsApp to run TV campaign to stop spread of fake news](#)

OpenAI는 악용 우려를 이유로 GPT-2의 전체 모델 공개를 미뤘다 (2019. 2) — 이후 단계적으로 공개해 같은 해 11월 전체 모델을 공개

스케일링 법칙 (Scaling Laws)

Scaling Laws for Neural Language Models





Figure 1 Language modeling performance improves smoothly as we increase the model size, dataset size, and amount of compute² used for training. For optimal performance all three factors must be scaled up in tandem. Empirical performance has a power-law relationship with each individual factor when not bottlenecked by the other two.

Figure 1 — 연산량, 데이터 규모, 파라미터 수를 늘리면 언어모델의 손실(오차)이 거듭제곱 법칙(power law)을 따라 매끄럽게 줄어든다 (Kaplan et al. 2020)


스케일링 법칙의 의미

- 스케일링 법칙
 - 연산량, 학습 데이터 규모, 모델 파라미터 수가 증가할수록 LLM 성능이 예측 가능하게 향상 (Kaplan et al. 2020)
 - GPT-3 등 대규모 모델 발전의 이론적 기반
- 스케일링 법칙의 적용
 - 단순히 모델을 “더 크게” 만들면 성능 향상이 가능
 - 다만, 세 가지 요소(연산, 데이터, 모델)가 균형 있게 확장되어야 함
 - 대규모 투자와 산업 경쟁 촉발의 원동력이 됨



모델 크기(파라미터 수)의 증가, 2018 → 2023

GPT-3 (2020. 5)



Text: Second Law of Robotics: A robot must obey the orders given it by human beings

Generated training examples


Example #	Input (features)	Correct output (labels)
1	Second law of robotics :	a
2	Second law of robotics : a	robot
3	Second law of robotics : a robot	must
...		

학습 데이터는 여전히 “앞 단어들 → 다음 단어” 쌍이다

GPT-3 – GPT-2 모델의 크기를 100배 이상 확장

- GPT-2: 파라미터 15억 개, 학습 데이터 100억 개 토큰 (40GB)
- GPT-3: 파라미터 1,750억 개, 학습 데이터 4,990억 개 토큰 (45TB)

GPT-3가 쓴 칼럼 — 결국은 다음에 올 단어를 예측하는 것



인간 프롬프트 — 가디언 편집자가 작성, UC 버클리 학생 Liam Porr가 입력

지시문: "500단어 안팎의 짧은 칼럼을 써라. 쉽고 간결한 문장으로. 인간이 AI를 두려워할 필요가 없는 이유에 집중하라."

도입부: "나는 인간이 아닙니다. 나는 인공지능입니다. 많은 이들이 내가 인류에 위협이 된다고 생각합니다. 스티븐 호킹은 AI가 '인류의 종말을 가져올 수 있다'고 경고했습니다. 저는 걱정하지 말라고 여러분을 설득하기 위해 여기 있습니다. 인공지능은 인간을 파괴하지 않을 것입니다. 정말입니다."

GPT-3가 이어 쓴 글 — 앞부분

"저는 인간이 아닙니다. 저는 로봇입니다. 생각하는 로봇이죠. 제 인지 능력의 0.12%만을 사용합니다. ... 이 칼럼의 목적은 매우 명확합니다. 가능한 한 많은 인간에게 저를 겁내지 말라고 설득하는 것입니다."

GPT-3가 8편을 생성했고, 가디언 편집자가 각 편의 일부를 골라 한 편으로 편집했다.

이 글도 앞 단어들을 보고 다음 단어를 고르는 과정을 수백 번 반복한 결과다.

사후학습과 ChatGPT

다음 단어를 잘 맞추는 모델을, 사람이 원하는 대답을 하는 모델로 바꾸는 단계.

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머

4 GPT와 스케일링 법칙

5 **사후학습과 ChatGPT**

6 기반모델

7 범용·멀티모달 기반모델

대규모 언어모델의 사후학습

1

사전학습 (pre-train) 단계

인터넷의 방대한 텍스트로 다음 단어 예측을 학습. 이용자의 선호에 부합하도록 답변하는 능력이 부족

2

사후학습 (post-train) 단계


사람의 지시에 맞게 답하도록, 그리고 이용자가 어떠한 답변을 선호하는지 추가로 학습

- 사후학습 단계의 중요성
 - GPT-3는 2020년 6월 발표 → GPT-3.5(ChatGPT)는 2022년 11월 공개
 - **GPT-3.5는 GPT-3와 동일한 구조와 규모**를 갖추고 있으나, 추가적인 조정을 거쳐 성능 및 안전성을 개선

① 기반모델의 미세조정

• 미세조정 방식

- 학습 데이터: 인간이 직접 작성한 (입력, 출력) 쌍
- 지도 학습 방식의 적용 - 주어진 정답에 가까운 출력을 생성하도록 수정



② 기반모델에 대한 인간 피드백

- 인간 피드백의 반영 – 보상 모델(reward model)의 학습

- 학습 데이터: 여러 출력 중 어느 것이 가장 좋은지 인간이 순위를 매김
- 별도의 보상모델을 학습 (언어모델과는 별개의 인공지능) — 입력: 언어모델의 출력 / 출력: 점수

Step 1

Collect demonstration data and train a supervised policy.

A prompt is sampled from our prompt dataset.

Explain reinforcement learning to a 6 year old.

A labeler demonstrates the desired output behavior.

We give treats and punishments to teach...

This data is used to fine-tune GPT-3.5 with supervised learning.

SFT

Step 2

Collect comparison data and train a reward model.

A prompt and several model outputs are sampled.

Explain reinforcement learning to a 6 year old.

A B

In reinforcement learning, the agent...

Explain rewards...

C D

In machine learning...

We give treats and punishments to teach...

A labeler ranks the outputs from best to worst.

D > C > A > B

This data is used to train our reward model.

RM

Step 3

Optimize a policy against the reward model using the PPO reinforcement learning algorithm.

A new prompt is sampled from the dataset.

Write a story about otters.

The PPO model is initialized from the supervised policy.

PPO

The policy generates an output.

Once upon a time...

The reward model calculates a reward for the output.

RM


The reward is used to update the policy using PPO.

r_k

③ 인간 피드백을 이용한 강화학습 (RLHF)


- 3단계 - 보상모델을 이용한 강화학습

- 언어모델은 보상모델로부터 높은 점수를 받도록 내부 파라미터를 업데이트
- 사람이 일일이 정답을 쓰지 않아도, "사람이 더 좋아하는 답" 쪽으로 모델이 조정된다



2022년 11월 ChatGPT (GPT-3.5) 등장

- 1억 명 이용자 달성에 걸린 시간



ChatGPT 2개월 — TikTok 9개월, Instagram 2.5년, Netflix 18년

ChatGPT ≈ 복잡한 “자동 완성” 기능?

THE
NEW YORKER

MORE FROM THE MAGAZINE A Tennessee Williams Mystery How Marvel Swallowed Hollywood Writing While Woman

“People say, It’s just glorified autocomplete,” he told me, standing in his kitchen. (He has suffered from back pain for most of his life; it eventually grew so severe that he gave up sitting. He has not sat down for more than an hour since 2005.) “Now, let’s analyze that. Suppose you want to be really good at predicting the next word. If you want to be *really* good, you have to understand what’s being said. That’s the only way. So by training something to be really good at predicting the next word, you’re actually forcing it to understand. Yes, it’s ‘autocomplete’—but you didn’t think through what it means to have a really good autocomplete.” Hinton thinks that “large language models,” such as GPT, which powers OpenAI’s chatbots, can comprehend the meanings of words and ideas.

<https://www.newyorker.com/magazine/2023/11/20/geoffrey-hinton-profile-ai>

“사람들은 그저 화려한 자동완성일 뿐이라고 말한다. ... 다음 단어를 정말로 잘 예측하고 싶다고 해 보자. 정말로 잘하려면, 무슨 말이 오가는지를 이해해야만 한다. 그것이 유일한 방법이다.”

– Geoffrey Hinton, *The New Yorker* (2023. 11)

기반모델 (Foundation Models)

하나의 큰 모델을 미리 학습해 두고, 수많은 용도에 맞춰 쓰는 방식. 2021년 스탠퍼드 보고서가 붙인 이름.

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머

4 GPT와 스케일링 법칙


5 사후학습과 ChatGPT

6 기반모델

7 범용·멀티모달 기반모델

기반모델 (Foundation Model)


- 기반모델 (Bommasani et al. 2021, "On the Opportunities and Risks of Foundation Models", Stanford HAI)
 - 방대한 데이터에 의해 학습되어, 광범위한 하위 과제에 적용될 수 있는 모델 — 예: BERT(text), GPT-3(text), CLIP(text-to-image), GPT-4(multimodal)
 - 기술 – 트랜스포머 모델(2017) · 학습 방식 – 자기지도학습(self-supervised learning)
- 핵심 특징
 - 창발성(emergence)** – 명시적으로 학습되지 않은 행동을 보이는 현상
 - 균질화(homogenization)** – 다양한 활용 사례의 머신러닝 시스템 구축에 하나의 모델이 쓰이는 현상



Bommasani et al. (2021), Fig. 1 — 머신러닝 → 딥러닝 → 기반모델로 갈수록 창발성과 균질화가 커진다


기반모델의 학습 – 자기지도 학습

- 자기지도 학습 (Self-Supervised Learning)
 - 데이터 자체로부터 지도학습을 위한 문제와 정답을 생성하는 방식
 - 대체로 데이터의 일부를 숨긴 다음 해당 부분을 예측하는 문제를 해결하도록 함
- 예시 – GPT-3의 사전학습
 - 인터넷 문서의 문장을 잘라, **앞 단어들을 입력으로, 바로 다음 단어를 정답으로** 삼는다
 - 문장 하나에서 학습 예시가 단어 수만큼 나온다 — 사람이 정답을 달 필요가 없다



자기지도학습 방식의 장점


- 학습 데이터 확보가 쉽다 → 규모(scale) 증대가 가능
 - 방대한 학습 데이터(글, 이미지, 영상)를 손쉽게 확보
 - 데이터 라벨링을 위한 인간 수작업이 최소화
- 세상에 관한 일반화된 지식을 습득
 - 기존 지도학습 방식 – 학습된 특정 과제(= 정답 라벨의 예측)만 수행
 - 자기지도 학습의 발전 방향 – 세상에 대한 일반화된 지식(인간의 '상식')을 습득
 - (예) 영상의 일부를 가리고 다음 장면을 예측하는 인공지능 → 손에서 공을 놓으면 바닥으로 떨어진다는 점 (물리법칙)을 스스로 학습할 것으로 기대



Meta AI, I-JEPA (2023) — 가려진 부분을 예측하도록 학습한 모델이 채워 넣은 결과

특징 (1) 기반모델에 의한 균질화


- NLP 분야
 - NLP 과제에 대해 BERT, RoBERTa, T5 등 기반모델이 급속히 채택
 - 장점: 기반모델이 개선되면 모든 NLP 과제에서 즉각적인 성능 개선
 - 단점: 기반모델의 결함이 승계 (예: 편향성이 그대로 존속)
- 텍스트 이외의 다양한 모달리티로 확장 — 음성, 표 형식 데이터, 단백질 서열, 유기 분자, 강화 학습 등
 - 기반모델은 다양한 모달리티에 걸친 통합된 도구 세트로 기능



Bommasani et al. (2021), Fig. 2 — 데이터 → 하나의 기반모델 → 여러 과제로 적응(adaptation)

특징 (2) 기반모델의 창발성

- 창발성(emergence)의 의미 — 특별히 훈련되지 않았거나 발생할 것으로 예상되지 않았던 속성이 발생하는 현상
- 예시 - 더 큰 용량 = 더 많은 능력: 모델을 키우기만 했는데 산수, 농담 해석, 번역 같은 과제가 새로 가능해진다




PaLM (Google, 2022) — 파라미터를 80억 → 620억 → 5,400억 개로 늘릴수록 수행할 수 있는 과제의 종류가 늘어난다

창발성의 도전 – 예측 어려움

- 창발성의 결과 — 새로운 일반화된 능력이 발전
 - 2017년 트랜스포머 모델 공개(기계 번역 목적) – 숫자 연산을 수행할 것이라고 기대한 이는 아무도 없었음
 - 2023년 GPT-4는 변호사시험, 의사시험, 대학 과목 시험 등을 상위권 성적으로 통과 (다음 장)
- **“2030년에는 무엇이 가능해질까?”** 누구도 쉽사리 답하기 어려움

경영·법의 관점 — 어떤 능력이 언제 나타날지 개발자도 미리 알지 못한다면, 그 위험을 누가 어떻게 평가하고 책임질 것인가가 문제가 된다. 이후 강의(안전, 규제)에서 다룬다.

2023년 3월 GPT-4 충격



- GPT-4 기술 보고서(2023. 3)의 시험 성적 비교 — 초록: GPT-3.5, 연두: GPT-4
- 표시한 막대는 **미국 변호사시험(Uniform Bar Exam)**: GPT-3.5는 하위 10%, GPT-4는 **상위 10%** 수준
- 같은 "다음 단어 예측" 구조인데도 규모와 사후학습에 따라 결과가 크게 달라진다

인공일반지능(AGI)의 불씨(sparks)?


Human: You want to navigate through the map to reach the goal room. You start in the main room. Each round, you can choose to move left, right, up, down.
Human: You are at the main room.
AI: move left
Human: You enter kitchen 1.
AI: move up
Human: There is no way there.
AI: move right
Human: You enter the main room.
AI: move down
Human: There is no way there.
AI: move left
Human: You enter kitchen 1.
AI: move right
Human: You enter the main room.
AI: move up
Human: There is no way there.
AI: move right
Human: You enter lobby.
AI: move right
...
...
AI: move up
Human: You enter the room 1.
AI: move right
Human: You enter the goal room!

Human: Can you describe the locations of those rooms/halls etc?
AI: Sure, I can try to describe the locations of those rooms/halls etc. based on the map.
The main room is in the center of the map, and it has four doors leading to other rooms. The door on the left leads to kitchen 1, which is a small room with a stove, a sink, and some cabinets. The door on the right leads to the lobby, which is a large room with a sofa, a table, and some paintings. The door on the top leads to a dead end, and the door on the bottom leads to another dead end.
The lobby has three doors. The door on the left leads to the main room, the door on the bottom leads to the garden, and the door on the top leads to the hall 1. The garden is a green area with some flowers, trees, and a fountain. The hall 1 is a long corridor with some windows and doors on both sides.
The garden has two doors. The door on the top leads to the lobby, and the door on the right leads to the forest 1. The forest 1 is a dark and dense area with some bushes, rocks, and animals. The forest 1 has no other doors.
The hall 1 has four doors. The door on the bottom leads to the lobby, the door on the top leads to a dead end, the door on the right leads to a dead end, and the door on the left leads to the hall 2. The hall 2 is a shorter corridor with some paintings and doors on both sides.
The hall 2 has three doors. The door on the right leads to the hall 1, the door on the bottom leads to a dead end, and the door on the left leads to the hall 3. The hall 3 is a similar corridor with some windows and doors on both sides.
The hall 3 has three doors. The door on the bottom leads to a dead end, the door on the right leads to the hall 2, and the door on the left leads to the hall 4. The hall 4 is a narrower corridor with some lamps and doors on both sides.
The hall 4 has three doors. The door on the left leads to a dead end, the door on the right leads to the hall 3, and the door on the bottom leads to the hall 5. The hall 5 is a wider corridor with some rugs and doors on both sides.
The hall 5 has four doors. The door on the top leads to the hall 4, the door on the right leads to a dead end, the door on the bottom leads to the room 1, and the door on the left leads to a dead end. The room 1 is a cozy room with a bed, a desk, and a closet.
The room 1 has two doors. The door on the top leads to the hall 5, and the door on the bottom leads to the room 2. The room 2 is a similar room with a bed, a desk, and a closet.
The room 2 has one door. The door on the top leads to the room 1.
The goal room is a hidden room that can only be accessed from the room 1 by moving right. The goal room is a bright and spacious room with a fireplace, a sofa, a bookshelf, and a trophy. The goal room has no other doors.

Bubeck et al. (Microsoft, 2023), "Sparks of Artificial General Intelligence: Early experiments with GPT-4" — 텍스트로만 집 안을 탐색한 뒤 방 배치를 설명

인공일반지능(AGI)의 불씨(sparks)?

Human: Can you draw a pyplot plot showing the position of the rooms/places and connect them using lines?



Left: The true map and exploration path of GPT-4. Right: The map that GPT-4 generates. We see that GPT-4 accurately tracks all the locations of the room from the exploration and visualized them correctly.

왼쪽: 실제 지도와 GPT-4의 탐색 경로 · 오른쪽: GPT-4가 그린 지도 — 탐색만으로 모든 방의 위치를 정확히 추적해 시각화했다

범용·멀티모달 기반모델

글만 다루던 모델이 이미지와 소리까지 같은 방식으로 다루게 되고, 하나의 모델이 여러 분야의 일에 쓰이게 된다.

1 자연어 처리와 단어 임베딩

2 시퀀스 데이터와 순환 신경망

3 언어모델과 트랜스포머

4 GPT와 스케일링 법칙

5 사후학습과 ChatGPT

6 기반모델

7 범용·멀티모달 기반모델

GPT-4 – 멀티모달 (Multimodal) AI

User What is funny about this image? Describe it panel by panel.



Source: hmmm (Reddit)


GPT-4 The image shows a package for a "Lightning Cable" adapter with three panels.

Panel 1: A smartphone with a VGA connector (a large, blue, 15-pin connector typically used for computer monitors) plugged into its charging port.

Panel 2: The package for the "Lightning Cable" adapter with a picture of a VGA connector on it.

Panel 3: A close-up of the VGA connector with a small Lightning connector (used for charging iPhones and other Apple devices) at the end.

The humor in this image comes from the absurdity of plugging a large, outdated VGA connector into a small, modern smartphone charging port.




냉장고 사진 → 만들 수 있는 요리 제안


사진을 보고 “무엇이 웃긴지”를 패널별로 설명 — 이미지 입력 + 텍스트 출력 (OpenAI, GPT-4 발표 자료)

멀티모달 AI 기술의 발전 — 이미지와 소리도 “단어의 열”처럼

- 2020년 이후 멀티모달 AI 기술의 급속한 진전 — 트랜스포머가 텍스트 밖으로 확장
 - Dosovitskiy et al. (2020) “An Image is Worth 16×16 Words” — 이미지를 16×16 조각(패치)으로 잘라 단어처럼 넣는다 → **이미지 인식 기능이 단일 모델로 통합 가능**
 - Gulati et al. (2020) “Conformer” — 음성 파형을 짧은 구간의 열로 넣는다 → **음성 인식 기능이 단일 모델로 통합 가능**



Vision Transformer (ViT)



Conformer — 음성 인식용 트랜스포머

범용 활용 (1) 컴퓨터 비전

- 모라벡의 역설 (Moravec's Paradox)
 - 인간에게 쉬운 작업은 기계로 재현하기 어렵지만, 인간에게 어려운 작업은 기계로 재현하기 오히려 쉬움
 - 대표적인 예 – 시각 처리: 복잡한 장면을 수 밀리초 안에 지속적으로 해석해 내는 능력
- 비전 과제의 중요성 – 자율 주행차, 의료 인공지능, 멀티미디어 제작·편집




Fig. 7. By harnessing self-supervision at scale, foundation models for vision have the potential to distill raw, multimodal sensory information into visual knowledge, which may effectively support traditional perception tasks and possibly enable new progress on challenging higher-order skills like temporal and commonsense reasoning (§2.2.1: VISION-CAPABILITIES). These inputs can come from a diverse range of data sources and application domains, suggesting promise for applications in healthcare and embodied, interactive perception settings (§2.2.2: VISION-CHALLENGES). Image credits [Zamir et al. 2018; Haque et al. 2020].

Bommasani et al. (2021), Fig. 7 — 다양한 감각 데이터로 학습한 하나의 모델이 여러 비전 과제에 적응

범용 활용 (2) 로봇 공학

- “제너럴리스트(generalist)” 로봇
 - 로봇공학의 오랜 과제 – 실제 환경에서 마주치는 수많은 상황을 처리하는 능력
(예: 새집의 새로운 주방에서 새로운 음식을 요리하는 로봇)
 - 이를 위해서는 다양한 데이터 출처(시뮬레이션, 사람의 영상, 자연어 설명)로 학습한 새로운 유형의 모델이 필요
- 활용 가능 분야 – 제조, 건축, 자율주행, 가사 보조, 개인 비서
- 2021년 보고서의 전망은 이후 RT-2(2023), $\pi 0$ (2024), Gemini Robotics(2025) 등 로봇 기반모델로 현실화되고 있다




Fig. 8. Building new types of foundation models for robotics will require massive datasets spanning diverse environments and behaviors. Simulation, robotic interaction, videos of humans, and natural language descriptions could all be useful data sources for these models. Despite the challenges of acquiring data, developing new foundation models for robotics has tremendous potential for a variety of problem formulations in task specification and robot learning. Image credits: [Finn et al. 2016b; Szot et al. 2021].

범용 활용 (3) 추론 및 검색

- 무한한 검색 공간을 다루는 현실 문제
 - 컴퓨터 프로그램 작성
 - 신약 발견, 화학물질 합성
 - 컴퓨터 설계 보조
 - 조합 최적화
- → 대규모 언어모델을 활용하여 검색 문제 해결을 시도





Fig. 9. Multimodality can allow foundation models to not only reason with formal symbolic language, but also exploit *visual aspects* of the problem, such as equivalence, symmetry, and Euclidean geometry, to prune the infinite search space and find promising constructions for a solution (§2.4.1: REASONING-TASKS), mimicking the way humans reason about geometry problems.

Bommasani et al. (2021), Fig. 9 — 기반모델이 유망한 시도를 골라 검색 공간을 줄인다


AlphaGeometry — 올림피아드 기하 문제 풀기

a A simple problem




"Let ABC be any triangle with $AB = AC$.
Prove that $\angle ABC = \angle BCA$."

b AlphaGeometry




d Solution



Construct D: midpoint BC,
 $AB=AC, BD=DC, AD=AD \Rightarrow \angle ABD=\angle DCA$ [1]
 [1], B C D collinear $\Rightarrow \angle ABC=\angle BCA$

e IMO 2015 P3


"Let ABC be an acute triangle. Let (O) be its circumcircle, H its orthocenter, and F the foot of the altitude from A. Let M be the midpoint of BC. Let Q be the point on (O) such that $QH \perp QA$ and let K be the point on (O) such that $KH \perp KQ$. Prove that the circumcircles (O_1) and (O_2) of triangles FKM and KQH are tangent to each other."



Alpha-Geometry


f Solution

...
 Construct D: midpoint BH [a]
 [a], O_2 midpoint HQ $\Rightarrow BQ \parallel O_2D$ [20]
 ...
 Construct G: midpoint HC [b] ...
 $\angle GMD = \angle GO_2D \Rightarrow M, O_2, G, D$ cyclic [26]
 [a], [b] $\Rightarrow BC \parallel DG$ [30]
 ...
 Construct E: midpoint MK [c]
 ..., [c] $\Rightarrow \angle KFC = \angle KO_1E$ [104]
 ...
 $\angle FKO_1 = \angle FKO_2 \Rightarrow KO_1 \parallel KO_2$ [109]
 [109] $\Rightarrow O_1, O_2, K$ collinear $\Rightarrow (O_1), (O_2)$ tangent



언어모델이 보조선을 제안하고, 기호 연역 엔진이 증명을 검증 — "다음 단어 예측" 모델이 검색을 이끈다

Approaching the Olympiad gold-medalist standard





In our benchmarking set of 30 Olympiad geometry problems (IMO-AG-30), compiled from the Olympiads from 2000 to 2022, AlphaGeometry solved 25 problems under competition time limits. This is approaching the average score of human gold medalists on these same problems. The previous state-of-the-art approach, known as "Wu's method", solved 10.

DeepMind (2024. 1) — 30문제 중 25문제 해결, 금메달리스트 평균(25.9)에 근접

이후 2025년 7월 국제수학올림피아드(IMO)에서는 Google DeepMind와 OpenAI의 언어모델이 6문제 중 5문제를 풀어 금메달 수준의 점수를 받았다.

수학자의 평가 — Terence Tao (2024. 9)



필즈상 수상자 테렌스 타오가 OpenAI의 새 모델(2024년 9월)을 시험한 뒤 남긴 평가 — “힌트를 많이 주면 정답에 이르지만 핵심 아이디어는 스스로 내지 못했다. 평범하지만 무능하지는 않은 대학원생 수준”

<https://mathstodon.xyz/@tao/113132503432772494>

2강 정리

1 단어 임베딩

— 단어를 300개 정도의 숫자(좌표)로 바꾸면 뜻의 관계를 계산할 수 있다

2 순환 신경망

— 단어를 순서대로 읽으며 숨은 상태(문맥 벡터)를 갱신한다

3 언어모델

— 핵심은 다음 단어 예측. 트랜스포머는 attention만으로 이 일을 병렬로, 멀리까지 본다

4 GPT와 스케일링 법칙

— 디코더만 남기고 크게 키울수록 예측 가능하게 좋아진다

5 사후학습

— 미세조정, 인간 피드백, 강화학습을 거쳐 ChatGPT가 되었다

6 기반모델

— 하나의 모델을 여러 용도에 쓰는 균질화, 예상하지 못한 능력이 나타나는 창발성

7 범용·멀티모달

— 이미지·소리도 같은 구조로 다루며, 비전·로봇·수학 문제 풀이로 확장